MBA USP ESALQ

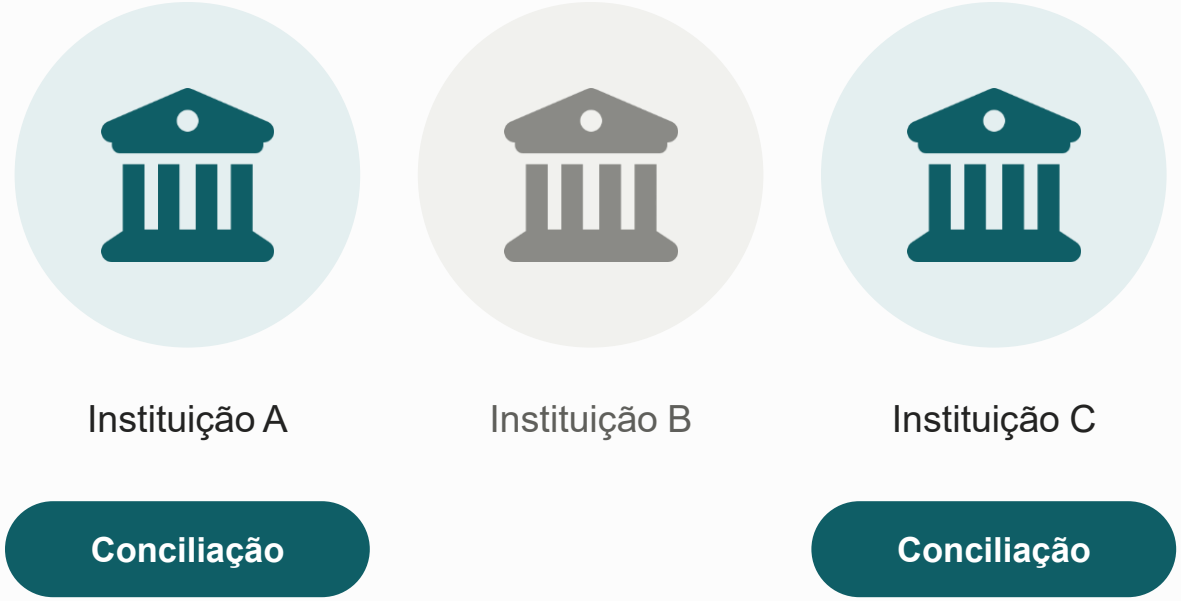
Representação de dados determina o desempenho de algoritmos na conciliação contábil automatizada

Artur Rios da Silva Oliveira
Orientador: Emerson Aparecido Mouco Júnior

Um problema que encontrei duas vezes

Três das maiores instituições financeiras do país.

Em **duas** delas, o mesmo problema: **a conciliação contábil.**



Anos como desenvolvedor de software em consultorias, atendendo o setor financeiro.

O que é conciliação contábil?

“Conferir se o que está no livro contábil bate com a realidade financeira.”

Comparar os saldos registrados na contabilidade com extratos, documentos e registros externos: bancos, fornecedores e clientes.



Identificar erros

e inconsistências



Garantir registros

corretos e confiáveis



Apoiar decisões

com informações precisas

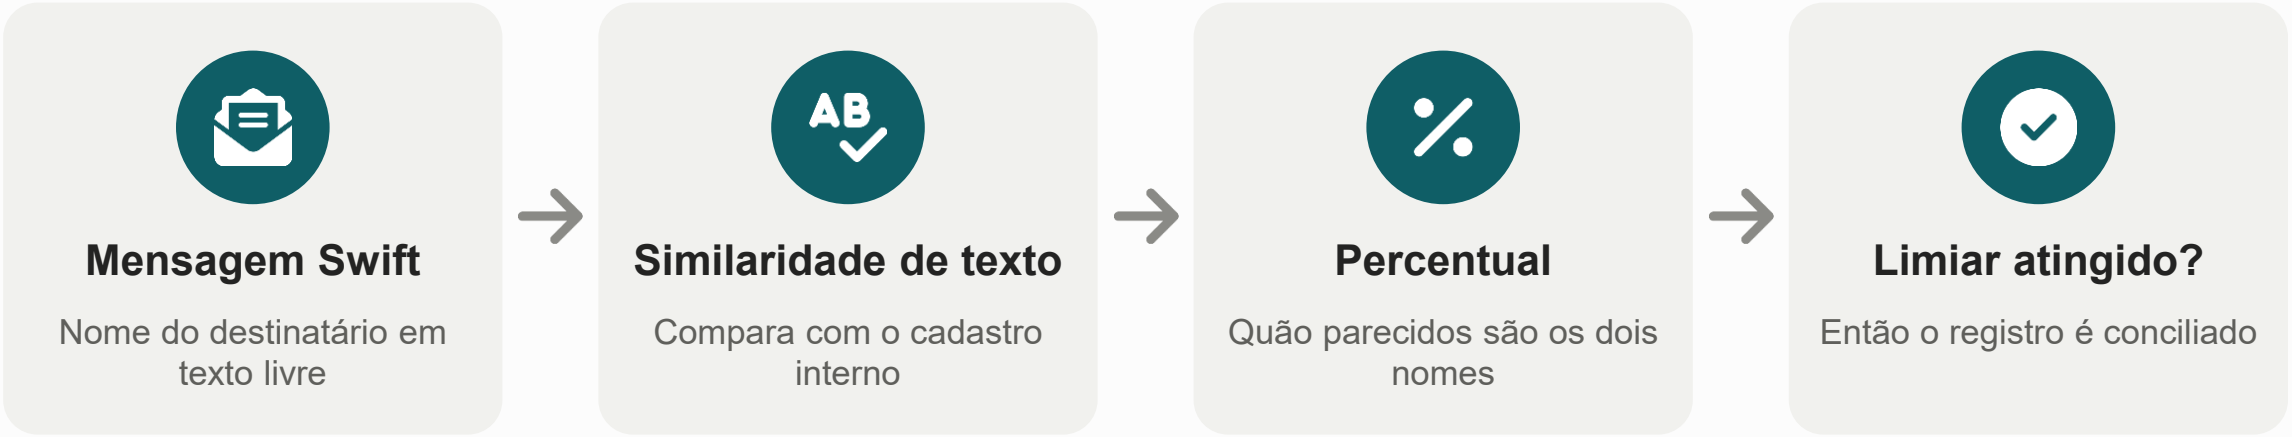


Permitir auditorias

com rastreabilidade

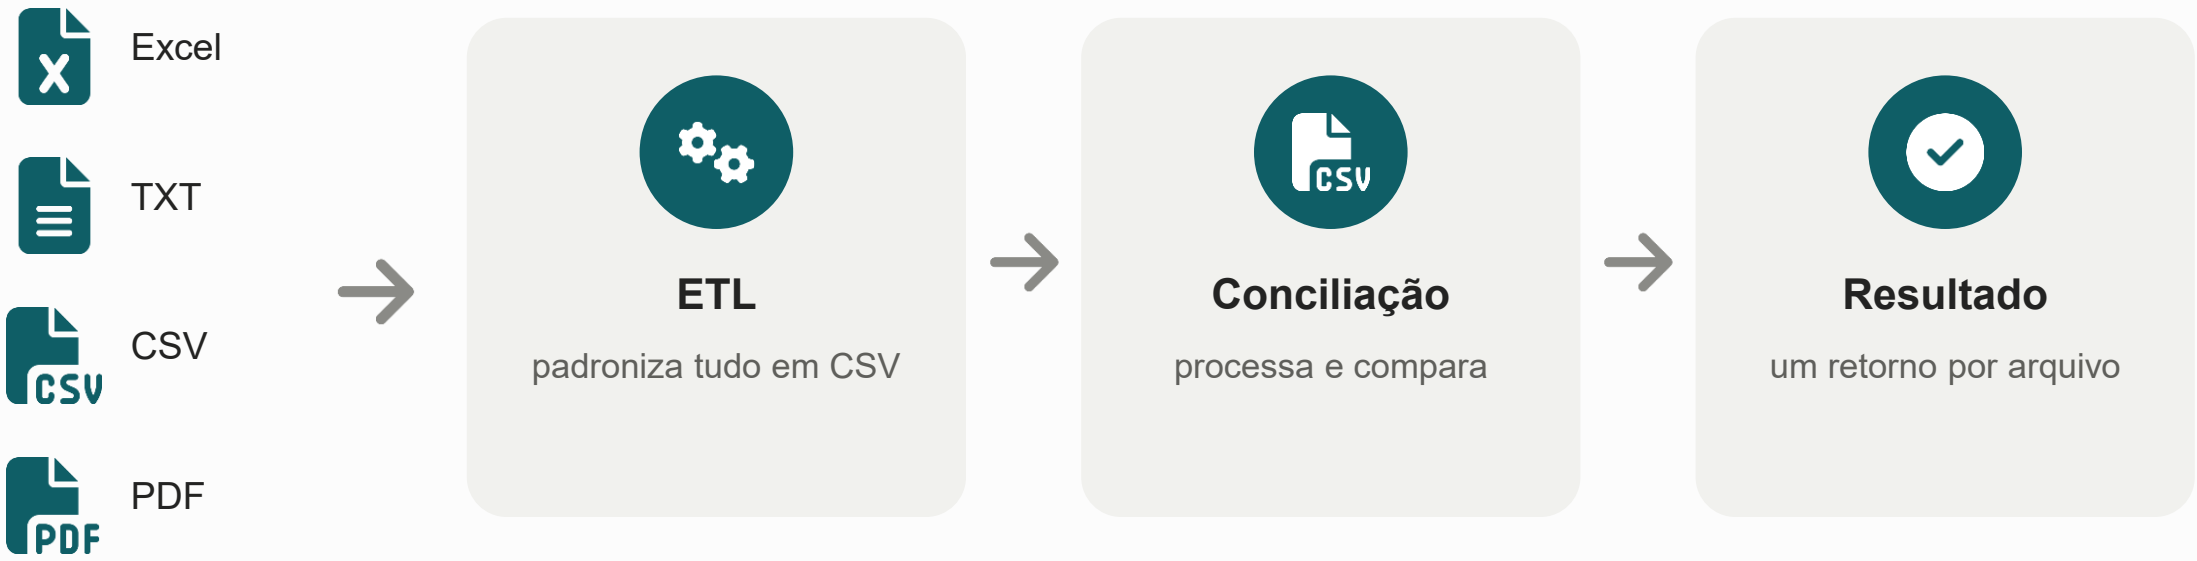
Caso 1: mensagens Swift com chave em texto livre

Conciliar mensagens Swift com operações internas, quando cada banco do mundo escreve a chave à sua maneira.



Exemplo: “JOHN SMITH TRADING LTD” × “John Smith Trading Limited” → alta similaridade → conciliado. A decisão é um limiar fixo, escrito à mão.

Caso 2: arquivos de B3 e CETIP em vários formatos



Sistema atual

Dependia de um layout fixo nos arquivos de entrada. Quando o layout mudava, falhava.

Modernização por metadados

Mais flexível, mas com custo de cloud e alta complexidade.

O que este projeto propõe

Pipeline ETL + Machine Learning

Demonstrar que a conciliação pode ser automatizada assim, e definir qual algoritmo é mais eficiente.

Pergunta de pesquisa

Qual algoritmo melhor automatiza a conciliação, e quanto do desempenho vem do algoritmo e quanto vem da representação dos dados?



Random Forest

Muitas árvores de decisão votando juntas



SVM

Fronteira de margem máxima entre as classes

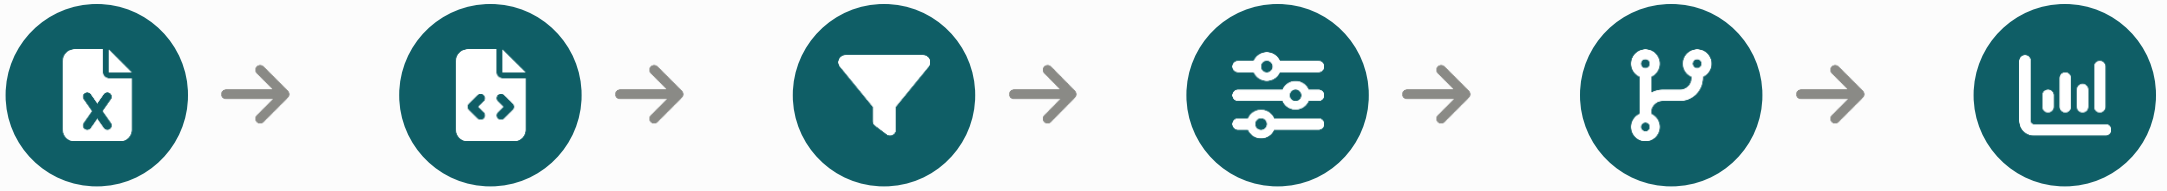


Regressão Logística

Fronteira linear, coeficientes interpretáveis

Hipótese: ML + ETL não só automatizaria a conciliação, como melhoraria sua qualidade, encontrando inconsistências que escapam às regras.

Como o projeto foi construído



Pagamentos
Planilha Excel

NFS-e
XML, padrão ABRASF

ETL
Carga, limpeza, rótulo

Atributos
Δ dias, Δ valor, ISS…

Modelos
RF, SVM e RL

Avaliação
Métricas e matrizes

7.500
pagamentos simulados

70%
com nota que bate

4
tipos de divergência

5
dobras de validação cruzada

Python + scikit-learn · parâmetros num arquivo de configuração · semente fixa: tudo reproduzível

Experimento 1: um resultado bom demais

F1-macro no conjunto de teste, cenário exato



No cenário flexível, o mesmo padrão: Random Forest com 1,0000 em todas as métricas.

100% de acerto, com desvio-padrão zero

Isso não é normal. É um sinal de alarme, não um sucesso.

A causa: o modelo apenas redescobria a regra

Regra de rotulagem

Conciliado ⇔

Δ dias ≤ tolerância E Δ valor ≤ tolerância

iguais

Atributos do modelo

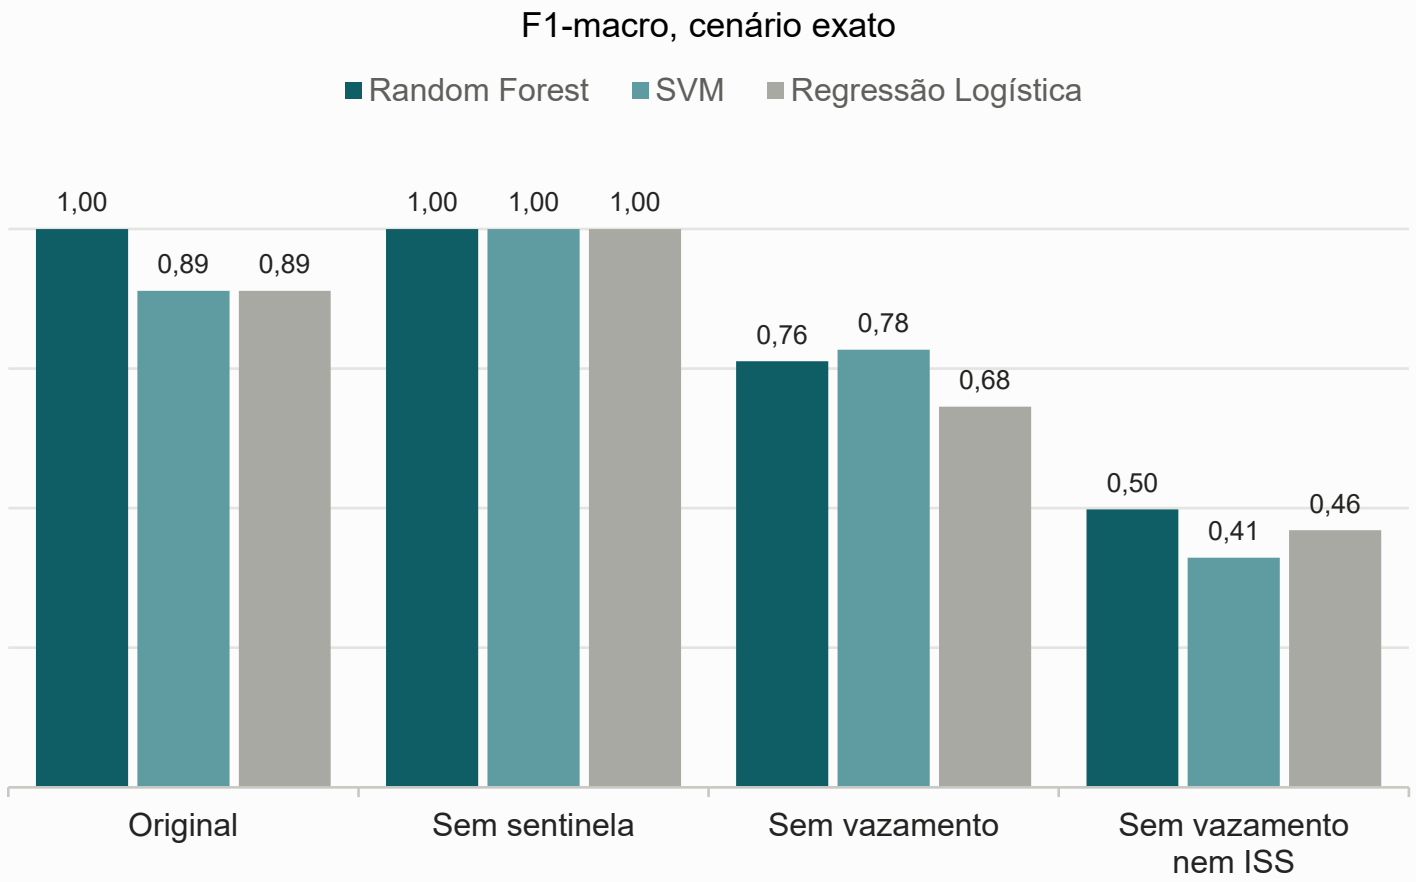
Δ dias, Δ valor, valor pago, ISS, alíquota, CNPJ, similaridade de texto

87%

da importância do modelo em Δ dias e Δ valor, as duas variáveis da regra

Vazamento de rótulo (label leakage): o rótulo é uma função exata de atributos que o modelo recebe. Ele não aprende a conciliar, só recupera a regra.

Experimento 2: ablação das variáveis



Mesmos dados, mesma divisão, só muda a representação.

Sem as variáveis da regra

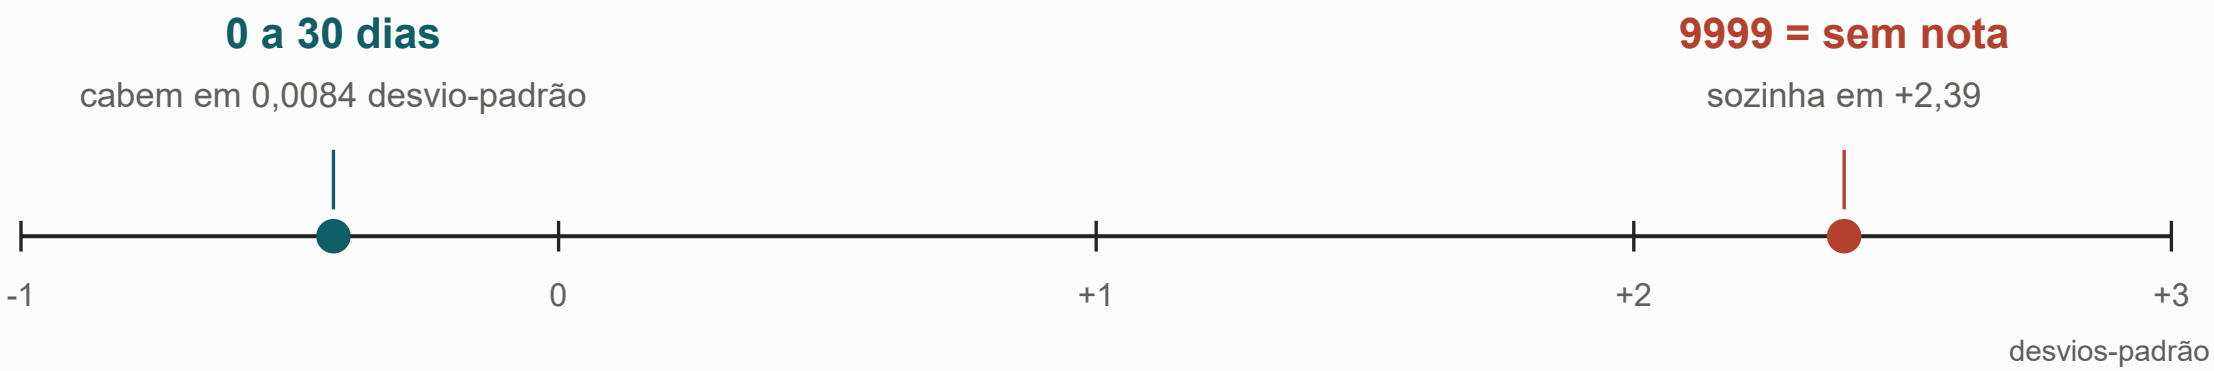
O F1 da Random Forest cai de 1,00 para 0,76, e o SVM passa à frente. A ordem se inverte.

Sem vazamento nenhum

Perto do acaso. Os modelos só detectavam pagamentos sem nota, o que um JOIN em SQL já faz.

A sentinela 9999 esmagou a escala

Pagamentos sem nota recebiam Δ dias = 9999. Depois da padronização (z-score):



128 / 128

falsos positivos eram divergências de data

Para o SVM e a Regressão Logística, pagar no dia certo ou 30 dias depois ficou indistinguível.

1,00

para os três algoritmos, com indicador explícito

Trocando a sentinela por “tem nota: sim/não”, a vantagem de 11 pontos da Random Forest desaparece.

O erro que importa

SVM e RL: **128 falsos positivos** e **0 falsos negativos**. Os dois erros não têm o mesmo peso.



Falso negativo

Um pagamento correto vai para revisão manual. Gera trabalho, mas o controle continua íntegro.

Afeta a eficiência



Falso positivo

Uma divergência é aprovada automaticamente e ninguém mais olha para ela: fica silenciada.

Afeta a eficácia do controle

Métrica certa: recall da classe de exceção sob precisão mínima, não acurácia nem F1. A NBC TA 530 faz a mesma distinção.

Experimento 3: uma comparação justa

1. Rótulo vem do gerador

Ele sabe qual pagamento quita qual nota. Nenhuma regra sobre os atributos.

2. Pares verdadeiros não são cópias

Retenções reais (IRRF, CSRF, ISS, INSS) e prazo típico de cada fornecedor.

3. Seleção pelo objetivo de controle

Maior recall de exceções com precisão mínima de 90%.

Guarda anti-vazamento

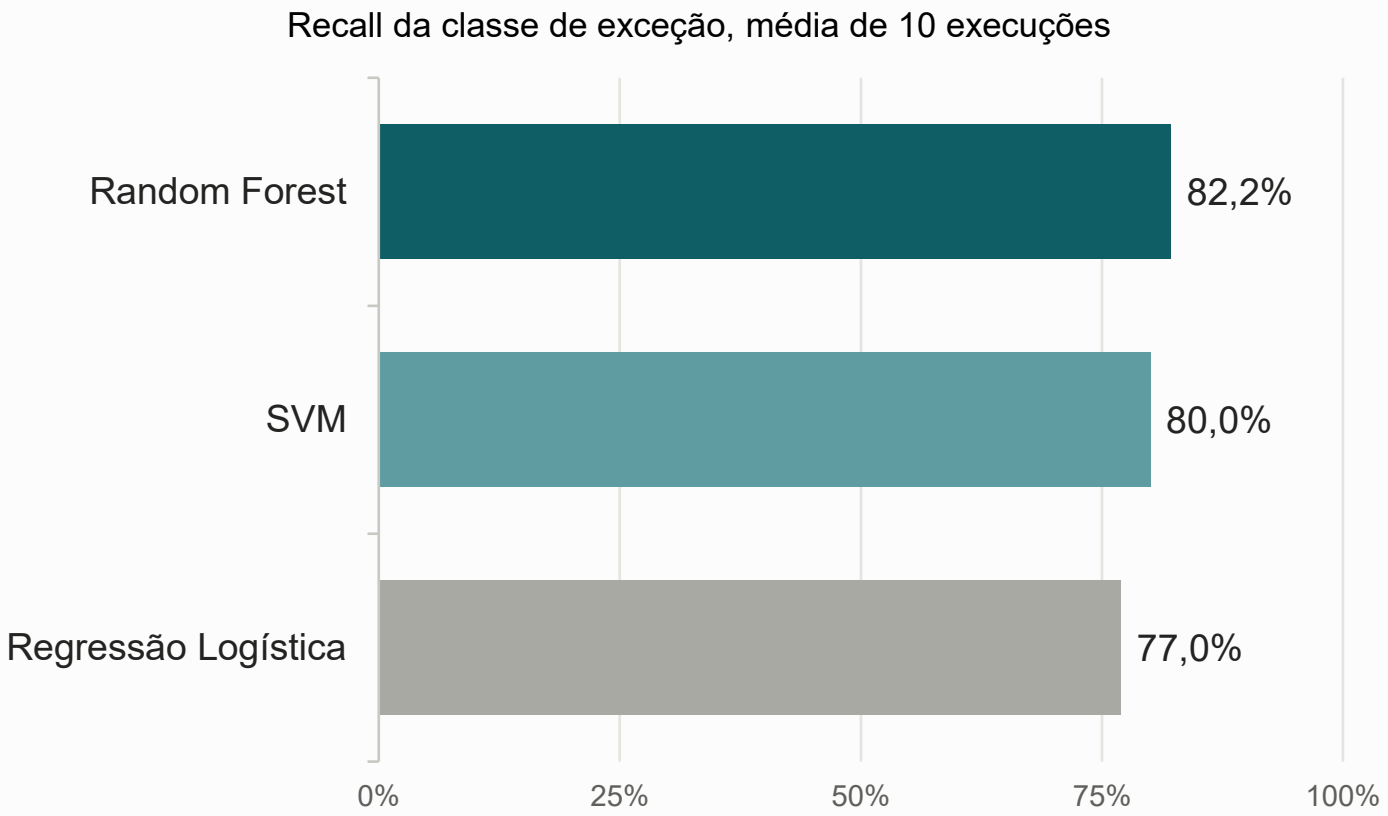
Testa cada variável sozinha e interrompe a execução se alguma passar de 95% de acurácia.

0,82 melhor variável isolada

A tarefa é genuína.

10 bases independentes · 7.500 pagamentos cada · 30% de exceções · testes de Friedman e Wilcoxon

Resultado: a Random Forest detecta mais exceções



p < 0,001

Friedman rejeita a equivalência no recall

p = 0,12

precisão: os três são equivalentes

27,6%

dos registros vão para revisão manual

Precisão mínima de 90% calibrada na validação. A vantagem não veio às custas de precisão.

Em unidades de controle interno

Divergências silenciadas em 15.000 pagamentos de teste (4.500 exceções, 10 execuções)

Random Forest

803

divergências silenciadas
446 revisões redundantes

SVM

899

divergências silenciadas
405 revisões redundantes

Regressão Logística

1.036

divergências silenciadas
374 revisões redundantes

Trocar RF por RL: +233 divergências silenciadas para poupar 72 revisões manuais.

Margem estreita: ~5 pontos entre o melhor e o pior. Interpretabilidade e custo também contam.

Respondendo à pergunta e à hipótese

Qual algoritmo?	**Random Forest**	Com rótulo independente e o critério certo, por margem estreita.
Algoritmo ou representação?	**Representação**	A codificação dos dados e a origem do rótulo pesaram mais. No 1º experimento, toda a diferença vinha da sentinela.
A hipótese se confirmou?	**Em parte**	Com regra conhecida, o ML só a reproduziu, com mais custo e opacidade. Com evidência ambígua, automatizou a triagem de exceções, mas faltou comparar com uma solução por regras.

O que se leva para a prática

Se a regra é conhecida, implemente a regra.

ML vale a pena onde a regra é desconhecida, instável ou difícil de escrever:

- Textos livres, como no caso Swift
- Pareamento de muitos-para-muitos
- Priorizar exceções por risco

1. Acurácia muito alta dispara uma auditoria do rótulo, não uma comemoração.
2. Nenhuma variável usada para gerar o rótulo entra como atributo.
3. Use um indicador explícito para “não encontrado”, não valores-sentinela.
4. Escolha o modelo pelo recall de exceções, sob precisão mínima.
5. Olhe a matriz de confusão, não só as métricas agregadas.

Limitações e próximos passos

Dados simulados

Próximo passo: Validar com base real, rotulada por especialistas.

Pareamento um-para-um

Próximo passo: Um pagamento pode quitar várias notas, e uma nota ser paga em parcelas.

Sem linha de base

Próximo passo: Comparar com regras e com detecção de anomalias, que dispensa rótulo.

Lição de método: cada verificação só enxerga a falha para a qual foi construída. O guarda anti-vazamento não pegou outros dois defeitos; a revisão crítica do código continua insubstituível.

Conclusão

Na conciliação automatizada, a representação dos dados e a origem do rótulo pesam mais do que a escolha do algoritmo.

O melhor algoritmo foi a Random Forest. A lição mais importante foi outra.

Obrigado(a)!



github.com/artur-rios/ml-accounting-reconciliation

MBA USP ESALQ